Statistical Data Analysis 2020/2021

Additional assignment 1

Emilia Wisnios

Zadanie

Otrzymują Państwo zbiór danych opisujących laptopy dostępne w sprzedaży pewnego sklepu internetowego. Zbiór `laptops.csv` zawiera następujące zmienne:

- `inches` - rozmiar przekątnej w calach
- `weight` - waga laptopa
- `price_euros` - cena laptopa w euro
- `company` - producent laptopa (1 - Acer, 2 - Asus, 3 - Dell, 4 - HP, 5 - Lenovo, 6 - MSI, 7 - Toshiba)
- `typename` - typ laptopa (1 - 2w1, 2 - gaming, 3 - netbook, 4 - notebook, 5 - ultrabook, 6 - stacja robocza)
- `ram` - ilość RAM laptopa (1 - 2GB, 2 - 8GB, 3 - 16GB, 4 - 32GB)

Państwa zadaniem jest w oparciu o podany zbiór weryfikacja następujących hipotez:

1. Stosowana ilość RAM w laptopie jest zależna od jego producenta.
2. Rozkład stosowanych pamięci RAM w notebookach HP i Lenovo jest taki sam
3. Średnia zlogarytmowana cena notebooka Dell i HP jest równa

W rozwiązaniu, dla każdej hipotezy proszę obliczyć wartość statystyki testowej, p-value oraz skonstruować obszar krytyczny. Wybór testu należy uzasadnić. Tam, gdzie zasadne, sprawdzić, czy założenia testu są spełnione.

Wczytujemy dane:

```
data <- read.table('laptops.csv', header = TRUE, sep = ';')
head(data)
```

```
##   inches weight price_euros company typename ram
## 1   15.6   1.86      575.00       4        4   2
## 2   15.6   2.10      400.00       1        4   1
## 3   14.0   1.30     1495.00       2        5   3
## 4   14.0   1.60      770.00       1        5   2
## 5   15.6   1.86      393.90       4        4   1
## 6   15.6   1.86      344.99       4        4   1
```

Stosowana ilość RAM w lapopie jest zależna od jego producenta

Sporzadzimy correlogram:

```
M <- cor(data)
corrplot(M, method = 'color')
```

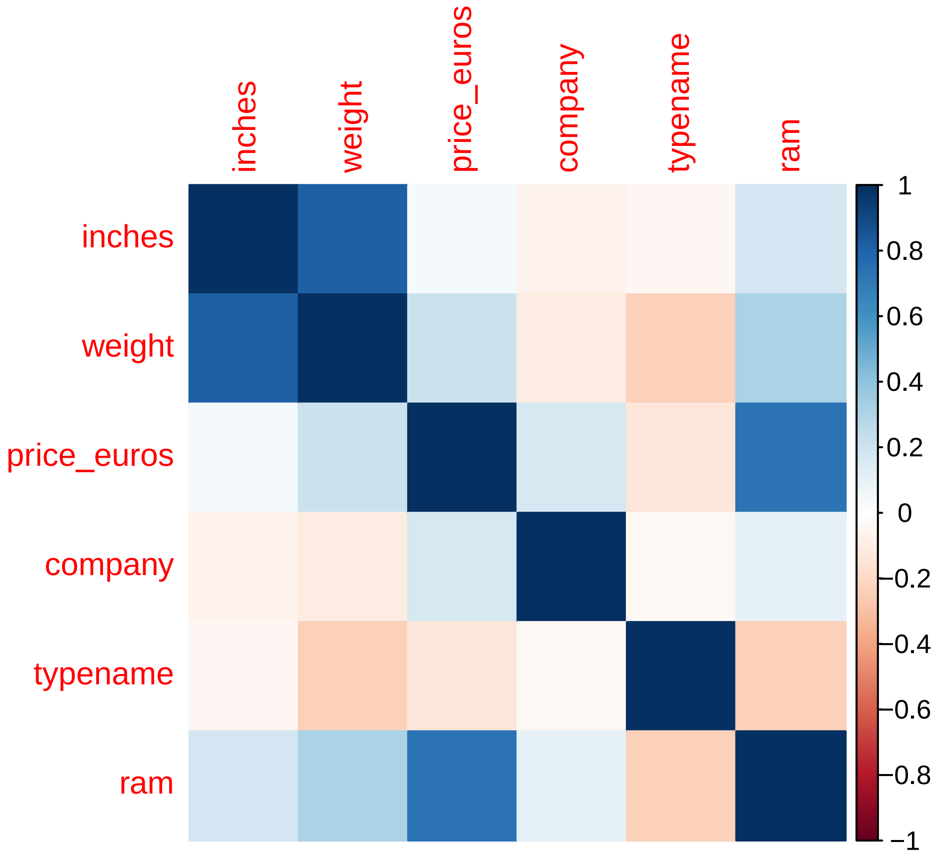

Możemy zauważyć, że kolumna 'ram' ma niską korelację z kolumną 'company', zatem na podstawie samego wykresu możemy sądzić, że stosowana ilość RAM nie jest zależna od jego producenta. Żeby zweryfikować hipotezę przeprowadzimy test niezależności χ^2. Wybieramy ten test, ponieważ mamy do czynienia z całą populacją. Przyjmijmy:

H_0 : Stosowana ilość RAM w laptopie jest niezależna od jego producenta

H_1 : Stosowana ilość RAM w laptopie NIE jest niezależna od jego producenta

oraz przyjmujemy poziom istotności $\alpha = 0.05$.

```
slownik_ram <- c('1' = '4GB', '2' = '8GB',
             '3' = '16GB', '4' = '32GB')
data$ram <- slownik_ram[as.character(data$ram)]
```

Poniżej znajduje się podsumowanie liczby laptopów z danym RAMem w zależoności od producenta:

```
data1 <- data
slownik_company <- c('1' = 'Acer', '2' = 'Asus',
             '3' = 'Dell', '4' = 'HP',
             '5' = 'Lenovo', '6' = 'MSI',
             '7' = 'Toshiba')
data1$company <- slownik_company[as.character(data1$company)]
table(data1$ram, data1$company)
```

```
##
##         Acer Asus Dell  HP Lenovo MSI Toshiba
##   16GB     4   35   54  13     39  31       8
##   32GB     0    3    7   0      3   1       1
##   4GB     57   45   63  90     89   0      14
```

```
##    8GB     33    61   161  142     141   22       25
```

Narysujmy wykres kwantyl-kwantyl, aby ocenić, czy zmienna ma rozkład normalny

```r
ggdensity(data$company, fill = "lightgray")
```

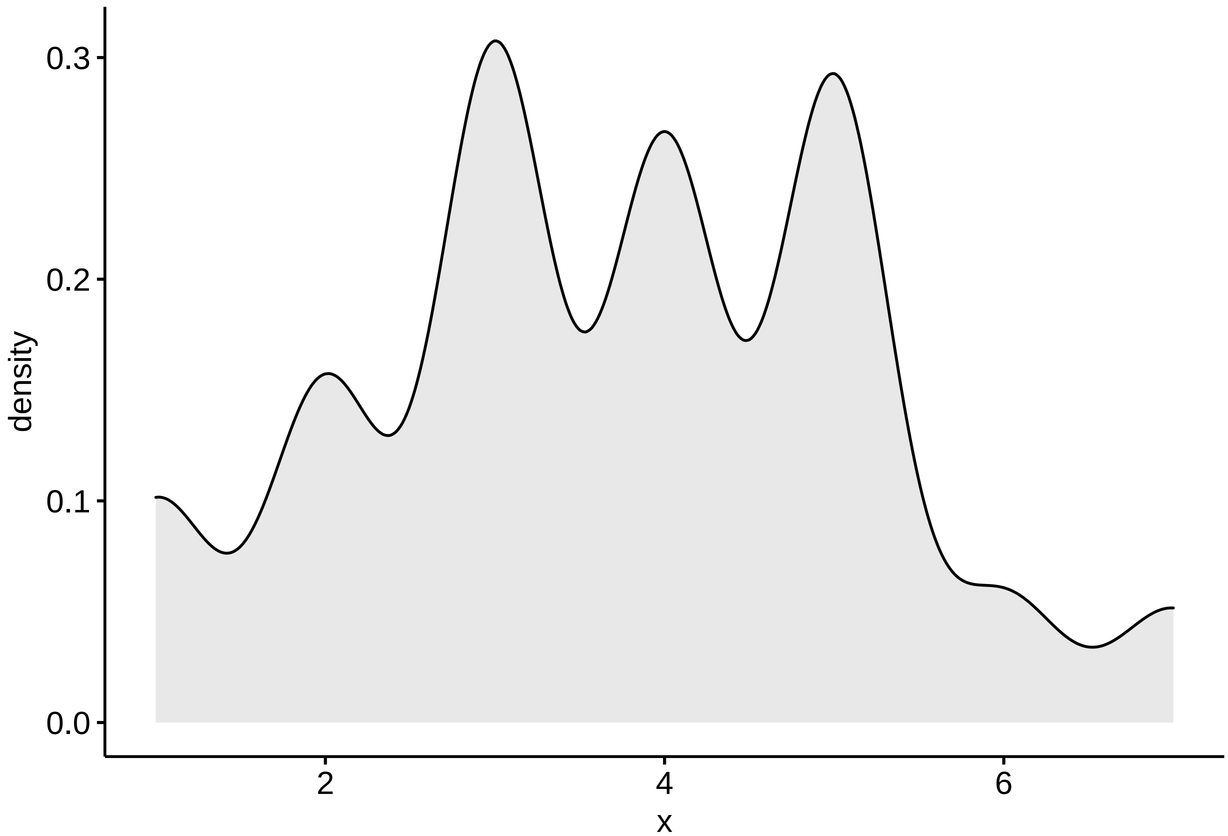


```r
ggqqplot(data$company)
```

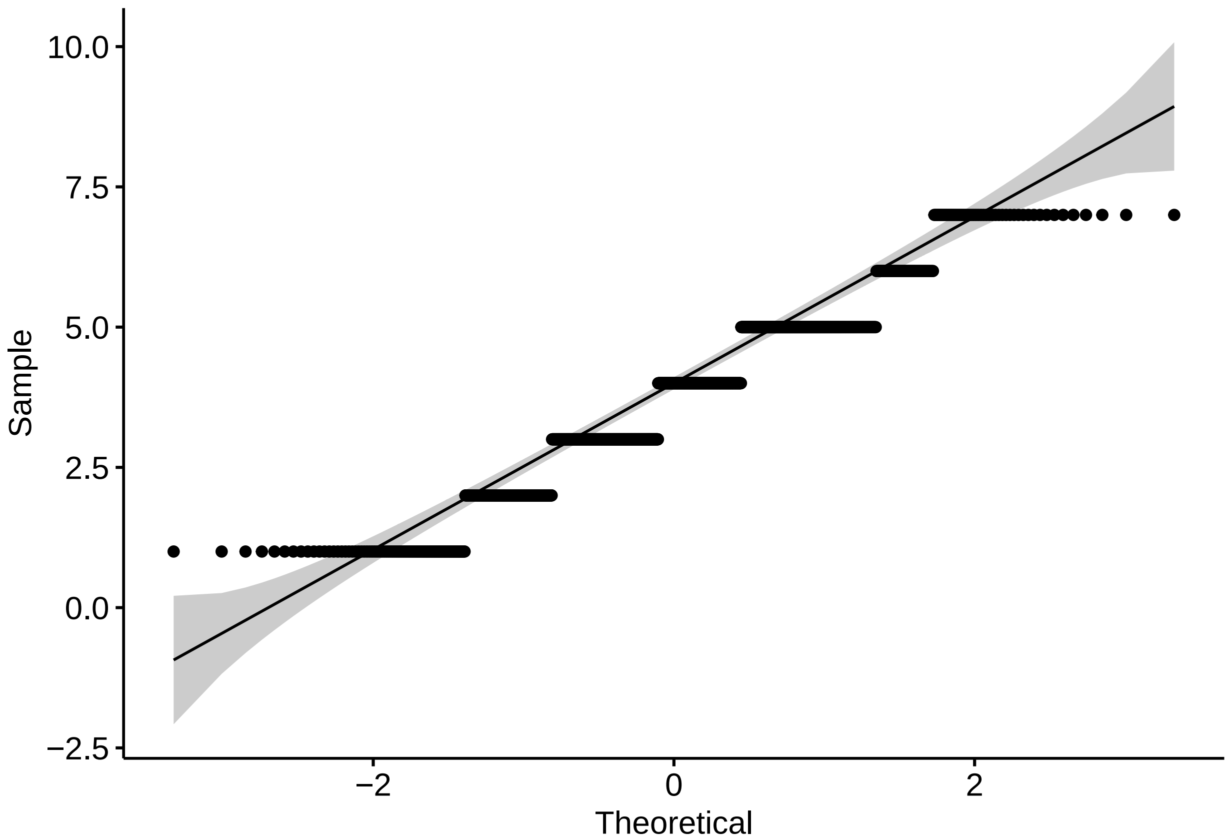

Zatem widzimy, że kolumna company nie ma rozkładu normalnego. Przeprowadzimy test χ^2

```
chisq <- chisq.test(table(data$ram, data$company))
```

```
## Warning in chisq.test(table(data$ram, data$company)): Chi-squared approximation
## may be incorrect
```

```
chisq
```

```
##
##  Pearson's Chi-squared test
##
## data:  table(data$ram, data$company)
## X-squared = 164.23, df = 18, p-value < 2.2e-16
```

Zauważmy, że otrzymaliśmy warning mówiący, że przeprowadzony test może nie być poprawny. Wynika to małych wartości, które są w naszej próbie. Aby sprawdzić czy powód jest prawdziwy pomnożymy wartości tabeli przez 1000.

```
chisq2 <- chisq.test(table(data$ram, data$company)*1000)
chisq2
```

```
##
##  Pearson's Chi-squared test
##
## data:  table(data$ram, data$company) * 1000
## X-squared = 164234, df = 18, p-value < 2.2e-16
```

Zatem istotnie powodem warningu są małe wartości próby.

```r
chisq$observed
```

```
##
##          1   2   3   4   5   6   7
##   16GB   4  35  54  13  39  31   8
##   32GB   0   3   7   0   3   1   1
##   4GB   57  45  63  90  89   0  14
##   8GB   33  61 161 142 141  22  25
```

```r
round(chisq$expected,2)
```

```
##
##              1      2      3      4      5     6     7
##   16GB 15.15 23.20  45.92  39.47  43.82  8.70  7.73
##   32GB  1.23  1.89   3.74   3.22   3.57  0.71  0.63
##   4GB  29.47 45.14  89.34  76.80  85.27 16.93 15.05
##   8GB  48.15 73.77 145.99 125.50 139.33 27.66 24.59
```

```r
round(chisq$residuals, 3)
```

```
##
##              1      2      3      4      5      6      7
##   16GB -2.864  2.449  1.192 -4.214 -0.729  7.560  0.096
##   32GB -1.111  0.806  1.683 -1.794 -0.303  0.345  0.465
##   4GB   5.072 -0.021 -2.787  1.506  0.404 -4.114 -0.270
##   8GB  -2.184 -1.486  1.242  1.473  0.141 -1.077  0.083
```

```r
contrib <- 100*chisq$residuals^2/chisq$statistic
round(contrib, 3)
```

```
##
##              1      2      3      4      5      6      7
##   16GB  4.994  3.653  0.866 10.811  0.323 34.800  0.006
##   32GB  0.752  0.396  1.725  1.959  0.056  0.073  0.132
##   4GB  15.663  0.000  4.729  1.381  0.099 10.307  0.044
##   8GB   2.903  1.345  0.939  1.320  0.012  0.706  0.004
```

```r
corrplot(contrib, is.cor = FALSE)
```

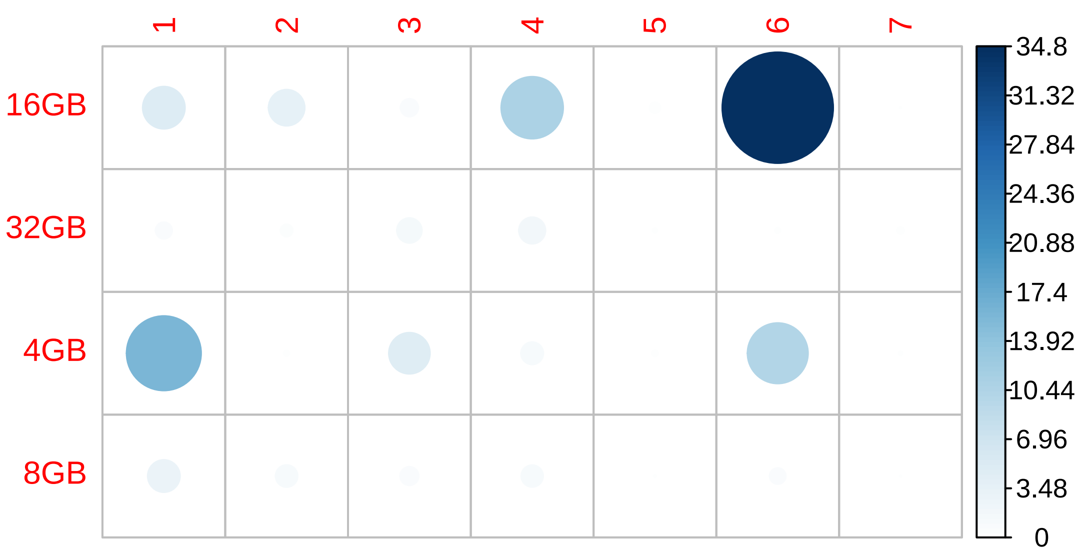

Na podstawie powyższego wykresu możemy stwierdzić, że:

1. Laptopy marki MSI są silnie powiązane z RAMem 16GB.
2. Laptopy marki Acer są silnie powiązane z RAMem 4GB.

```
chisq$p.value
```

```
## [1] 1.232738e-25
```

Na poziomie istotności $\alpha = 0.05$ otrzymana p-value jest mniejsza od wartości α, zatem mamy podstawę do odrzucenia hipotezy zerowej. Zatem stosowana ilość RAM w laptopie jest zależna od jego producenta, co oznacza, że sugerowanie się korelacją nie było zasadne.

Rozkład stosowanych pamięci RAM w notebookach HP i Lenovo jest taki sam

Skorzystamy z fragmentu poprzedniego podpunktu.

```
data_true <- read.table('laptops.csv', header = TRUE, sep = ';')
data_2 <- data_true[data_true$company == 4 | data_true$company == 5, ]
data_2pom <- data_2
slownik_company <- c('1' = 'Acer', '2' = 'Asus',
             '3' = 'Dell', '4' = 'HP',
             '5' = 'Lenovo', '6' = 'MSI',
             '7' = 'Toshiba')
slownik_ram <- c('1' = '4GB', '2' = '8GB',
             '3' = '16GB', '4' = '32GB')
data_2pom$ram <- slownik_ram[as.character(data_2pom$ram)]
data_2pom$company <- slownik_company[as.character(data_2pom$company)]
table(data_2pom$ram, data_2pom$company)
```

```
##
##         HP Lenovo
##   16GB  13     39
##   32GB   0      3
##   4GB   90     89
##   8GB  142    141
```

Przeprowadzimy zgodności χ^2. Nie możemy przeprowadzić t-testu, ponieważ próba nie jest rozkładu normalnego (widać na wykresach niżej).

Przyjmijmy:

H_0 : Rozkłady stosowanych pamięci RAM w markach laptopów HP i Lenovo NIE są zgodne.

H_1 : Rozkłady stosowanych pamięci RAM w markach laptopów HP i Lenovo są zgodne.

oraz przyjmujemy poziom istotności $\alpha = 0.05$.

```
chisq.test(table(data_2$ram, data_2$company))
```

```
## Warning in chisq.test(table(data_2$ram, data_2$company)): Chi-squared
## approximation may be incorrect
```

```
##
##  Pearson's Chi-squared test
##
## data:  table(data_2$ram, data_2$company)
```

```
## X-squared = 14.639, df = 3, p-value = 0.002153
```

Podobnie jak w popdunkcie a) otrzymaliśmy ostrzeżenie, związane z małymi warościami w próbie. Na poziomie istotności $\alpha = 0.05$ otrzymana p-value jest mniejsza od wartości α, zatem mamy podstawę do odrzucenia hipotezy zerowej, czyli rozkład stosowanych pamięci RAM w notebookach HP i Lenovo jest zgodny. Narysujmy oba rozkłady, aby potwierdzić nasz wynik:

```
data_2_hp <- data_2[data_2$company == 4, ]
ggdensity(data_2_hp$ram, fill = "lightgray")
```

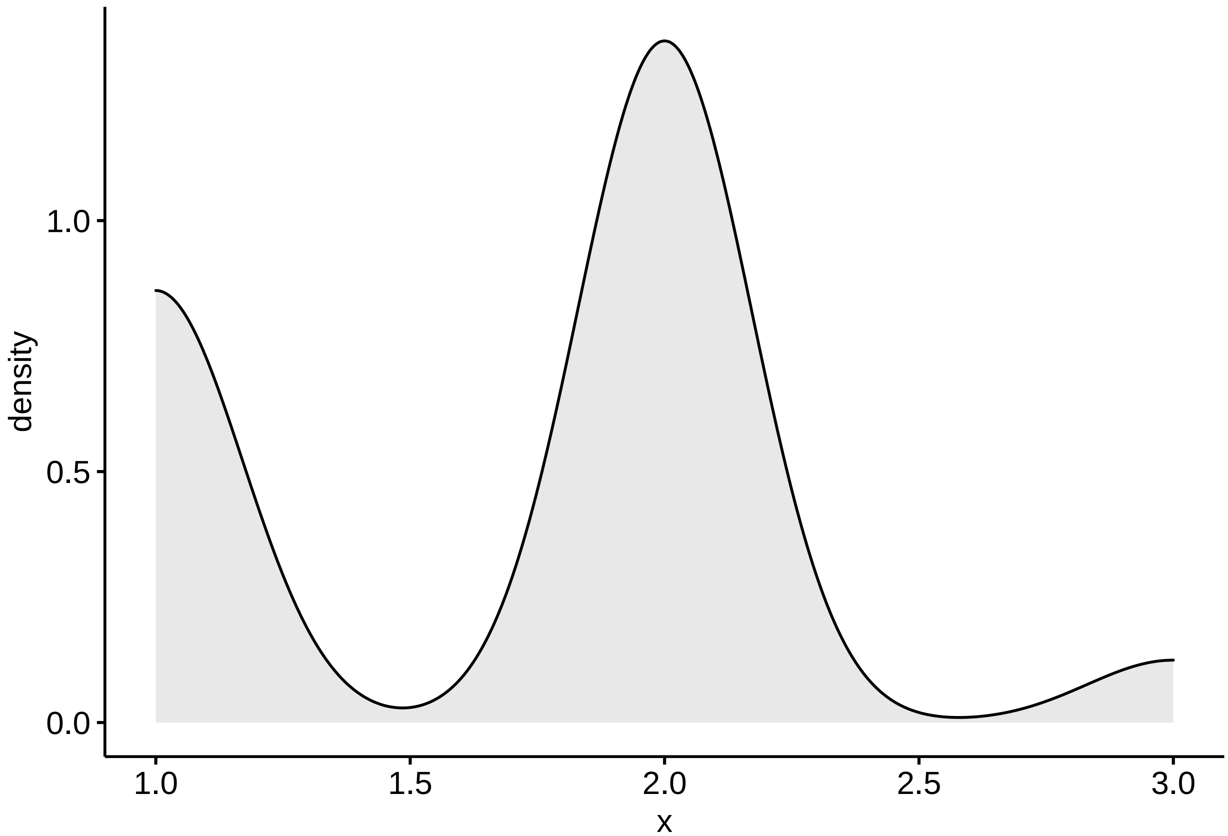


```
ggqqplot(data_2_hp$ram)
```

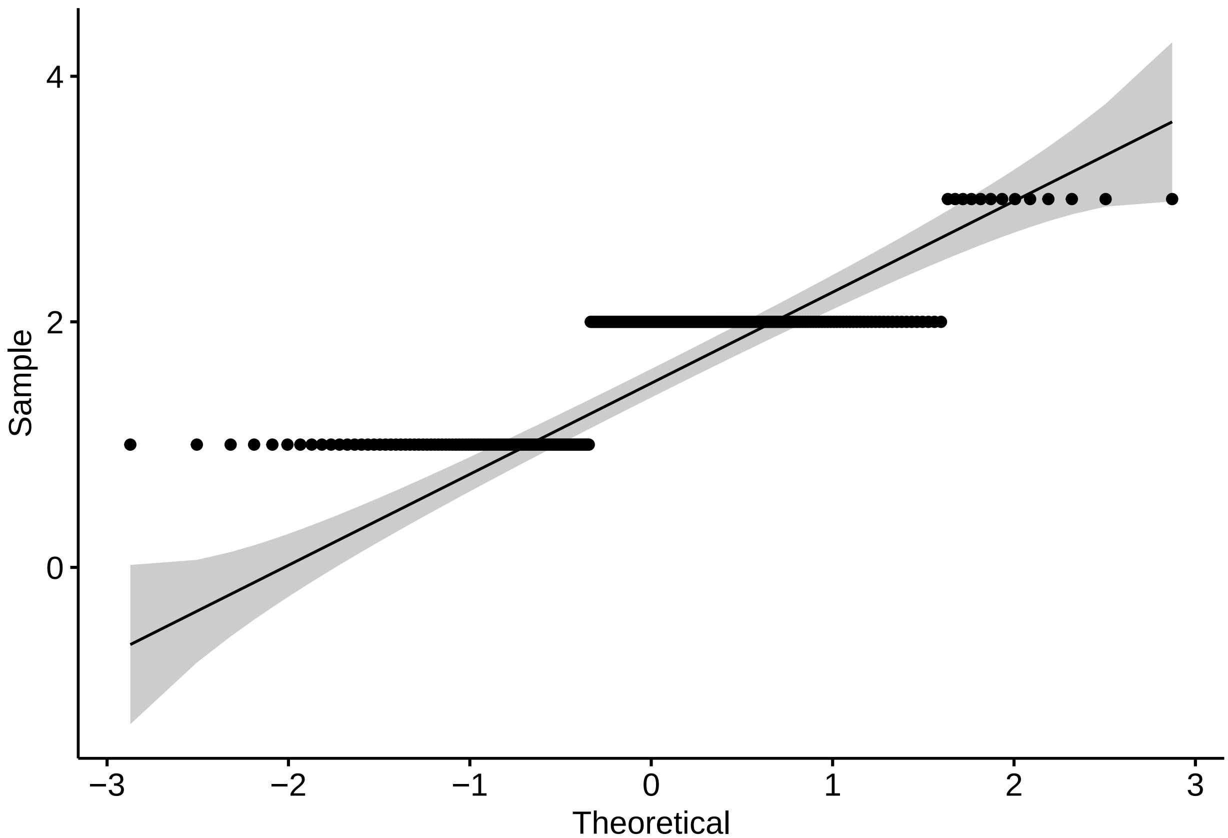


```
data_2_lenovo <- data_2[data_2$company == 5, ]
ggdensity(data_2_lenovo$ram, fill = "lightgray")
```

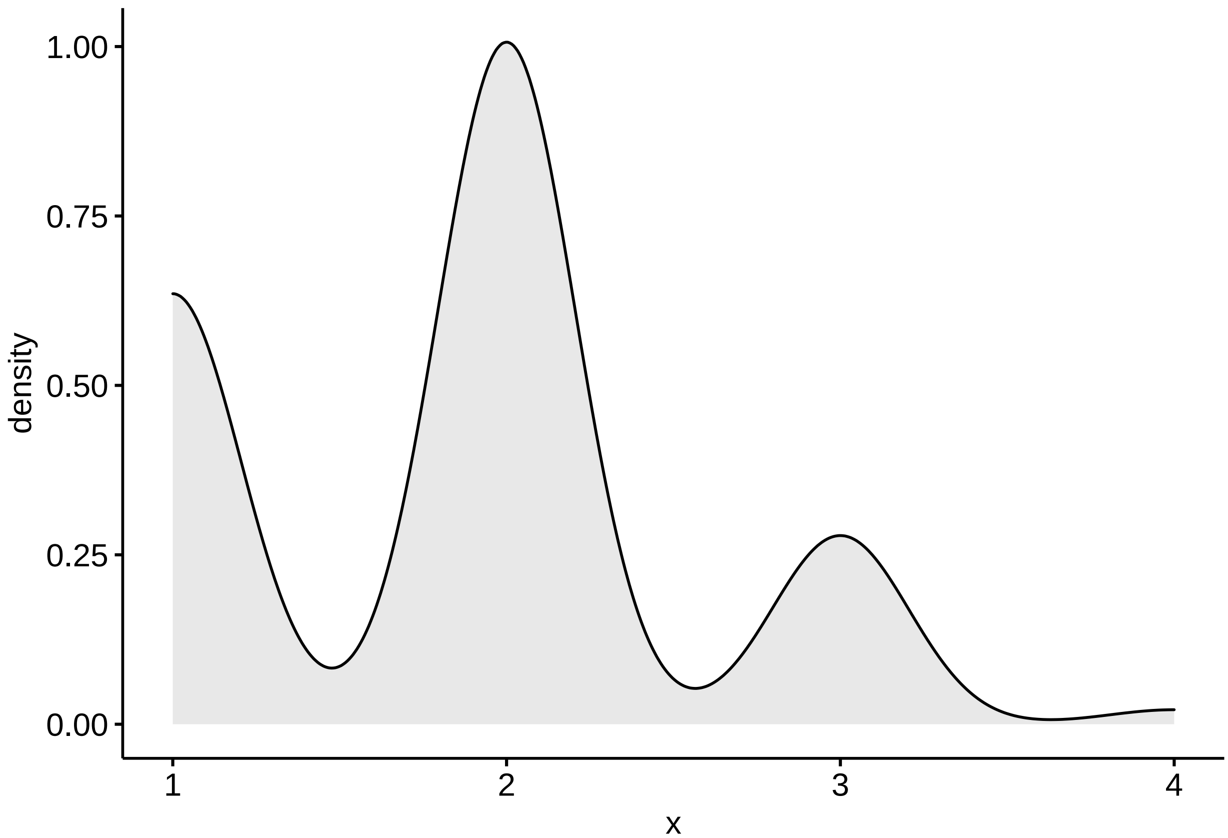


```
ggqqplot(data_2_lenovo$ram)
```

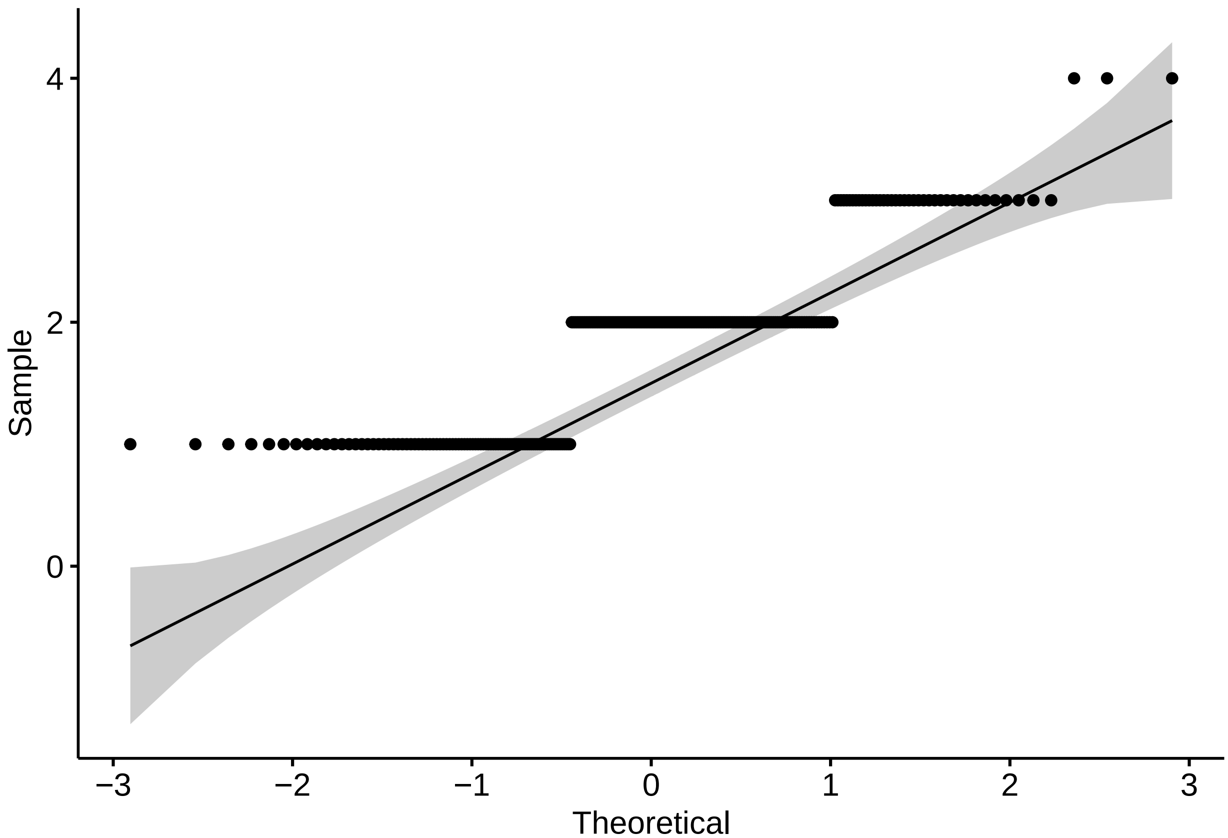

Średnia zlogarytmowana cena notebooka Dell i HP jest równa

Aby zweryfikować ostatnią hipotezę użyjemy t-testu. Niech:

H_0 : średnie zlogarytmowane ceny notebooka Dell i HP nie mają statystycznie dużych różnic

H_1 : średnie zlogarytmowane ceny notebooka Dell i HP mają statystycznie dużą różnicę

oraz przyjmujemy poziom istotności $\alpha = 0.05$.

Na początku obliczmy logarytmy cen notebooków.

```
data$price_euros <- sapply(data$price_euros, log)
data_dell <- data[data$company == 3, ]
data_hp <- data[data$company == 4, ]
```

Następnie obliczmy t-test. Wybieramy akurat ten test, ponieważ chcemy porównać ze sobą dwie grupy (a nie populację jak w przypadku a)). W tym celu powinniśmy sprawdzić czy rozkład wyników zmiennej zależnej w każdej z grup jest zbliżony do rozkładu normalnego.

```r
ggdensity(data_dell$price_euros, fill = "lightgray")
```

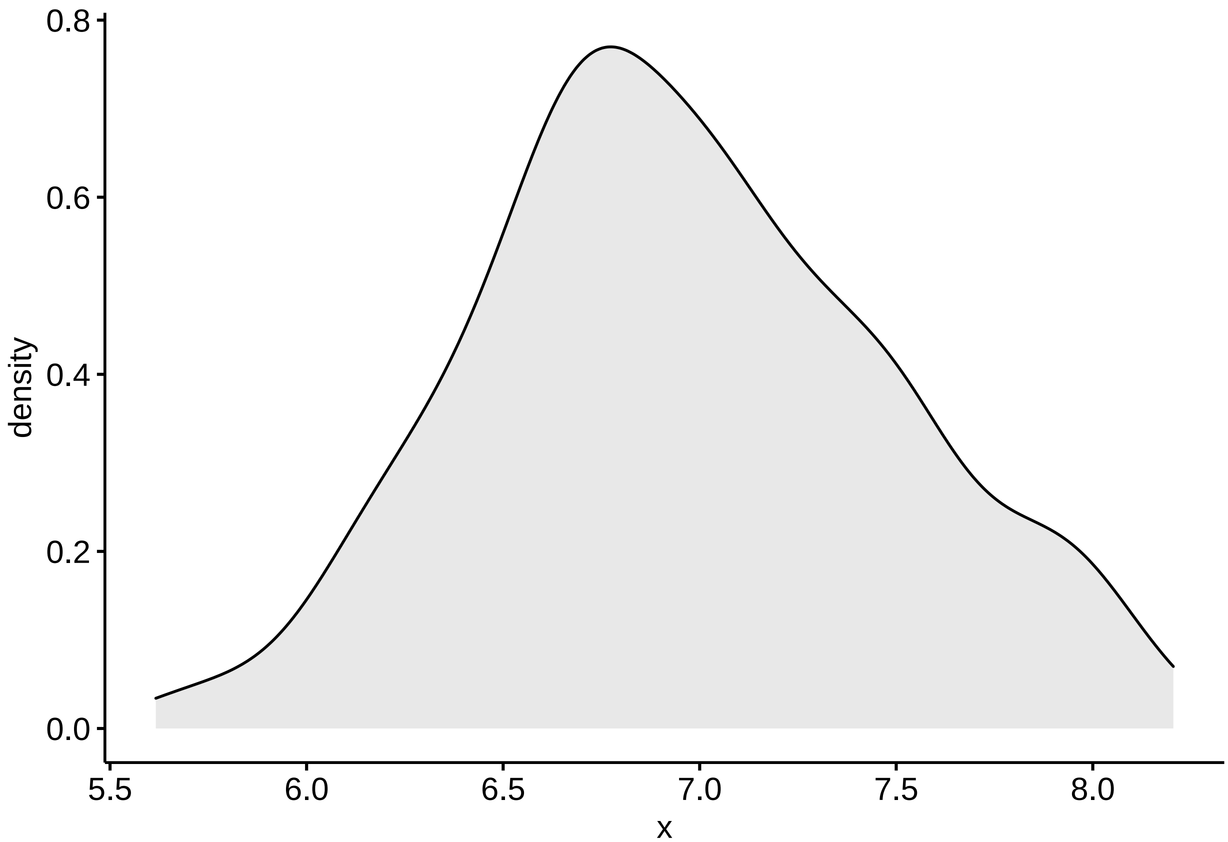


```r
ggqqplot(data_dell$price_euros)
```

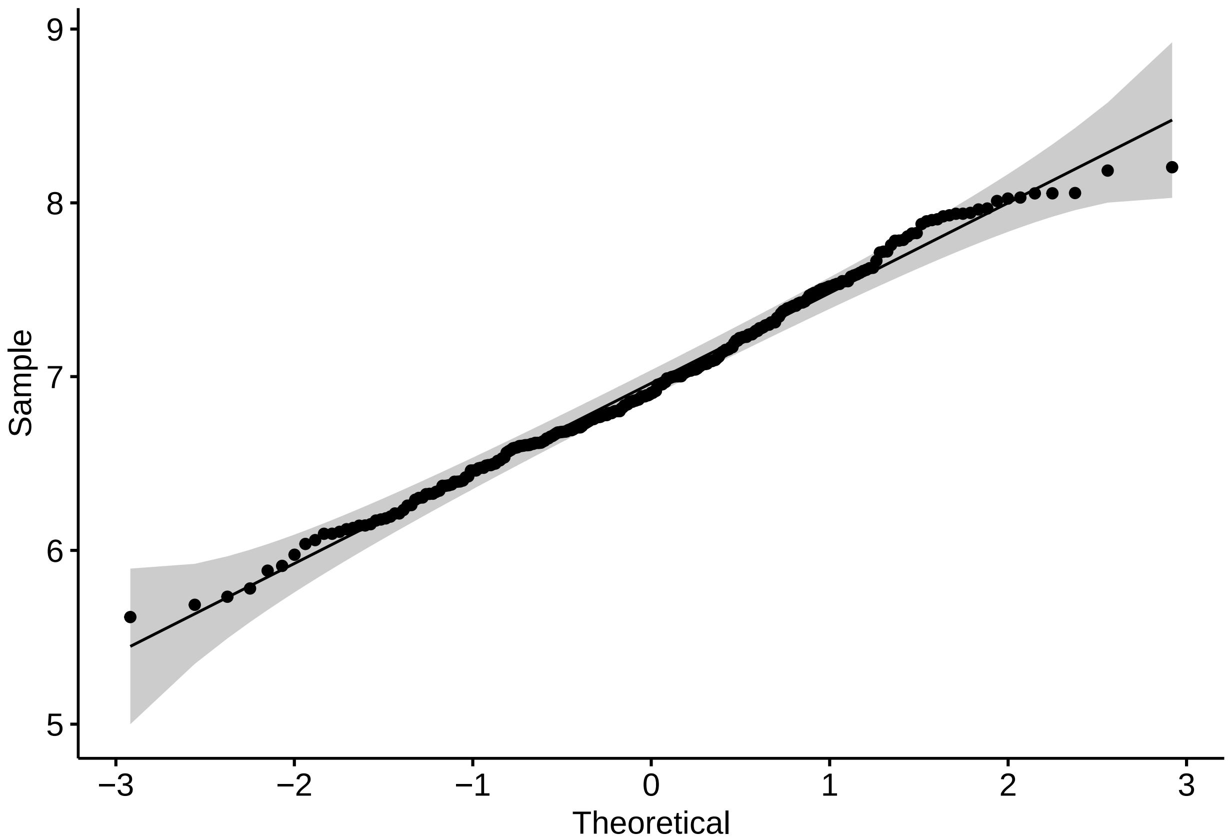


```
ggdensity(data_hp$price_euros, fill = "lightgray")
```

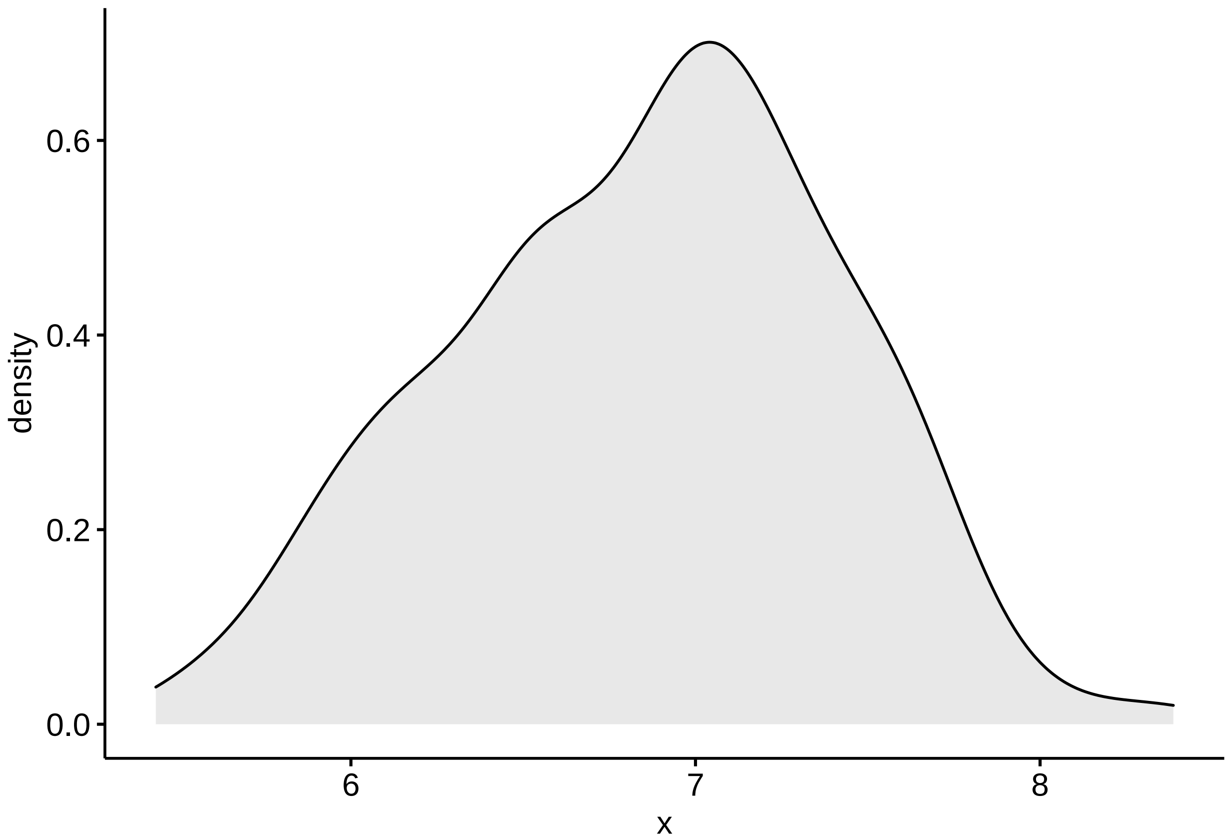


```
ggqqplot(data_hp$price_euros)
```

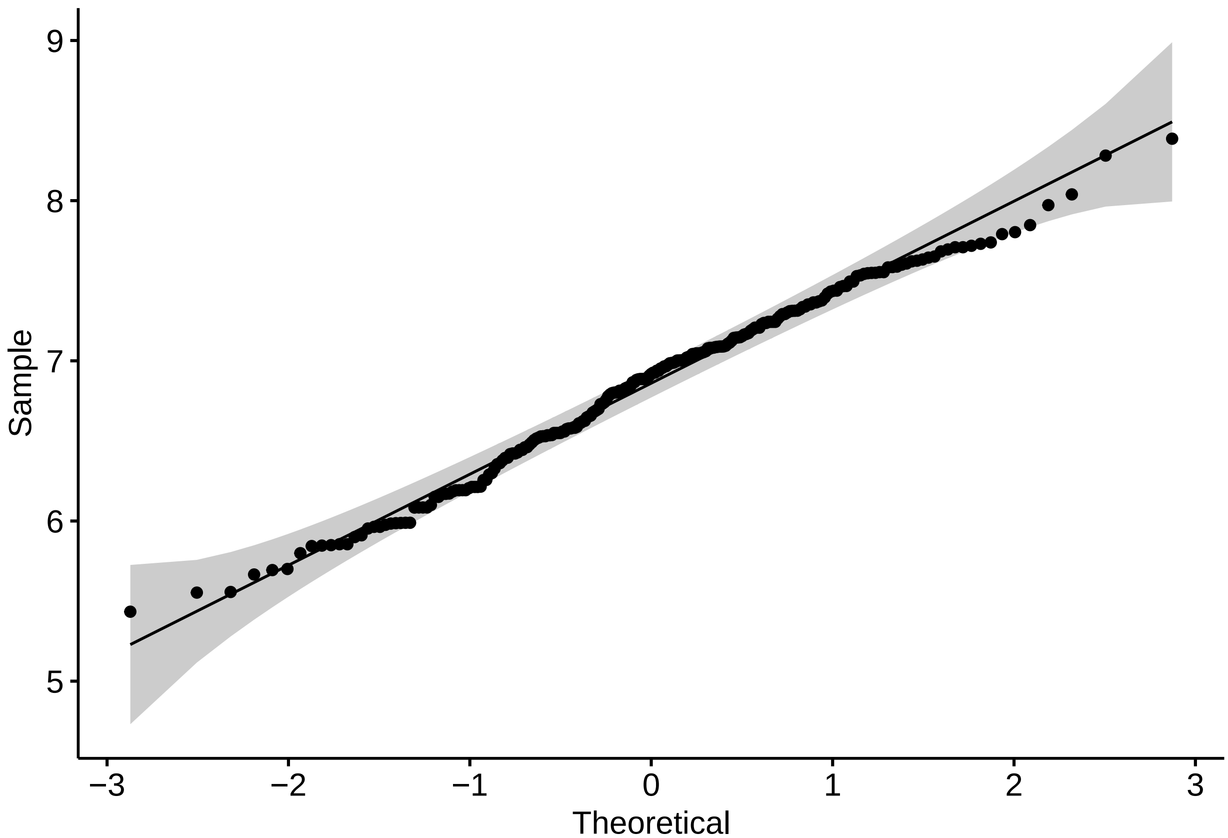

Rozkłady są zbliżone do rozkładu normalnego, możemy więc przeprowadzić t-test:

```
t_test_ceny <- t.test(data_dell$price_euros, data_hp$price_euros)
t_test_ceny
```

```
##
##  Welch Two Sample t-test
##
## data:  data_dell$price_euros and data_hp$price_euros
## t = 2.1851, df = 503.74, p-value = 0.02934
## alternative hypothesis: true difference in means is not equal to 0
## 95 percent confidence interval:
##  0.01045117 0.19677745
## sample estimates:
## mean of x mean of y
##  6.958167  6.854553
```

Na poziomie istotności $\alpha = 0.05$ otrzymana p-value jest mniejsza od wartości α, zatem mamy podstawę do odrzucenia hipotezy zerowej. Czyli w średniej zlogarytmowanej cenie notebooka Dell i HP są statystycznie ważne różnice. Możemy to potwierdzić obliczając odpowiednie średnie:

```
mean_dell <- mean(data_dell$price_euros)
mean_dell
```

```
## [1] 6.958167
```

```
mean_hp <- mean(data_hp$price_euros)
mean_hp
```

```
## [1] 6.854553
```

Ponadto sprawdżmy odpowiednie mediany i odchylenia standardowe

```
mediana_dell <- median(data_dell$price_euros)
mediana_dell
```

```
## [1] 6.906755
```

```
mediana_hp <- median(data_hp$price_euros)
mediana_hp
```

```
## [1] 6.91821
```

```
sd_dell <- sd(data_dell$price_euros)
sd_dell
```

```
## [1] 0.5240001
```

```
sd_hp <- sd(data_hp$price_euros)
sd_hp
```

```
## [1] 0.56112
```