

Zestaw 1

Statystyczna Analiza Danych

Emilia Wiśnios

18 marca 2021

1. Generowanie zmiennych losowych

Niech X będzie zmienną losową o ciągłej i ściśle rosnącej dystrybuancie F oraz niech U będzie zmienną losową o rozkładzie jednostajnym na odcinku $[0, 1]$. Pokaż, że

- zmienna losowa $F^{-1}(U)$ ma dystrybuantę F .
- zmienna losowa $F(X)$ ma rozkład jednostajny na odcinku $[0, 1]$.

Rozwiązanie:

X - zmienna losowa

Dystrybuanta jest określona wzorem

$$F(t) = P(X \leq t)$$

- $P(F^{-1}(U) \leq t) = P(F \circ F^{-1}(U) \leq F(t)) = P(U \leq F(t))$
Korzystając ze znanej dystrybuanty dla rozkładu jednostajnego na odcinku $[0, 1]$ (identyczność) mamy, że

$$P(U \leq F(t)) = F(t)$$

- $X \sim F$

$$X \stackrel{d}{=} F^{-1}(U) \Rightarrow F(X) \stackrel{d}{=} F \circ F^{-1}(U) \stackrel{d}{=} U$$

2. Rozkład dwumianowy. Choroba Taya-Sachsa.

Jeśli oboje rodziców jest dotkniętych chorobą, ich dziecko ma $1/4$ szans odziedziczenia jej. Para chorych ma czwórkę dzieci. Jakie jest prawdopodobieństwo zachorowania dla danej liczby $l = 0, 1, \dots, 4$ dzieci?

Rozwiązanie:

Chcemy obliczyć prawdopodobieństwo

$$P(l \text{ chorych dzieci}) = \binom{4}{l} \left(\frac{1}{4}\right)^l \left(\frac{3}{4}\right)^{4-l} \quad l = 0, 1, 2, 3, 4$$

3. Niech X będzie zmienną losową o rozkładzie Poissona, z parametrem λ . Wyprowadź

$$E(X) = Var(X) = \lambda$$

Rozwiązanie:

$$X \sim \text{Poiss}(\lambda)$$

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k = 0, 1, 2, \dots$$

$$E(X) = \sum_{k=0}^{\infty} k P(X = k) = \sum_{k=0}^{\infty} k \frac{\lambda^k e^{-\lambda}}{k!} = \sum_{k=1}^{\infty} \frac{\lambda^k e^{-\lambda}}{(k-1)!} = \lambda \sum_{k=1}^{\infty} \frac{\lambda^{k-1} e^{-\lambda}}{(k-1)!} = \lambda e^{\lambda} e^{-\lambda} = \lambda$$

$$Var(X) = E(X - EX)^2 = EX^2 - (EX)^2$$

$$EX^2 = \sum_{k=0}^{\infty} k^2 P(X = k) = \sum_{k=0}^{\infty} k^2 \frac{\lambda^k e^{-\lambda}}{k!} = \sum_{k=1}^{\infty} \frac{k \lambda^k e^{-\lambda}}{(k-1)!} = \lambda \sum_{k=1}^{\infty} \frac{k \lambda^{k-1} e^{-\lambda}}{(k-1)!} = \lambda E(X+1) = \lambda(\lambda+1)$$

$$Var(X) = \lambda(\lambda+1) - \lambda^2 = \lambda$$

4. Rozkład dwumianowy vs Poissona

Założmy, że prawdopodobieństwo uzyskania sukcesu w schemacie Bernoulliego maleje wraz ze wzrostem liczby doświadczeń w ten sposób, że $np_n = \lambda$ dla dowolnego n gdzie λ jest ustaloną liczbą dodatnią. Pokaż, że

$$\lim_{n \rightarrow \infty} P(K_n = k) = \frac{\lambda^k}{k!} e^{-\lambda}, \quad k = 0, 1, \dots$$

gdzie K_n to zmienna losowa o rozkładzie Binomial(n, p_n).

Rozwiązanie:

$$\begin{aligned} P(K_n = k) &= \binom{n}{k} p_n^k (1 - p_n)^{n-k} = \frac{n!}{(n-k)! k!} \frac{(np_n)^k}{n^k} \left(1 - \frac{np_n}{n}\right)^{n-k} = \\ &= \frac{n(n-1)\dots(n-k+1)}{n \cdot n \cdot \dots \cdot n} \frac{\lambda^k (1 - \frac{\lambda}{n})^n}{k! (1 - \frac{\lambda}{n})^k} \xrightarrow{n \rightarrow \infty} \frac{\lambda^k}{k!} e^{-\lambda} \end{aligned}$$

5. Brak pamięci rozkładu wykładniczego.

- Rozważmy komponent konstrukcyjny jakiejś maszyny i wybierzmy rozkład wykładniczy z parametrem λ jako model jego wytrzymałości (ile czasu T działa).
- Założmy, że komponent działa już czas s .
- Jakie jest prawdopodobieństwo, że będzie działał jeszcze dodatkowo t jednostek czasu?

Rozwiązanie:

Gęstość $X \sim f$

$$P(X \in B) = \int_B f(x) dx$$

$$X \sim \exp(\lambda)$$

$$f(x) = \lambda e^{-\lambda x}, \quad x \geq 0$$

$$T \sim \exp(\lambda)$$

Prawdopodobieństwo warunkowe

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

$$P(T > t + s | T > s) = \frac{P(T > t + s \cap T > s)}{P(T > s)} = \frac{P(T > t + s)}{P(T > s)}$$

$$P(T > s) = \int_s^\infty \lambda e^{-\lambda x} dx = -e^{-\lambda x} \Big|_s^\infty = 0 - (-e^{-\lambda s}) = e^{-\lambda s}$$

$$P(T > t + s | T > s) = \frac{P(T > t + s \cap T > s)}{P(T > s)} = \frac{P(T > t + s)}{P(T > s)} = e^{-\lambda t}$$

Tylko ten rozkład ma własność braku pamięci.

Funkcja przeżycia

$$\bar{F}(t) = 1 - F(t)$$

$$\bar{F}(t + s) = \bar{F}(t) \cdot \bar{F}(s)$$

Ile jest funkcji ciągłych spełniających te warunki? Jedna co do podstawy.

6. Kwantyl rozkładu Laplace'a

Podać wzór na kwantyl rzędu p w rozkładzie o gęstości

$$f(x) = \frac{1}{2} e^{-|x|/2}$$

Rozwiązanie:

mediana = kwantyl rzędu $1/2$
kwantyl rzędu p

$$P(X \leq q(p)) \geq p$$

$$P(X \leq q(p)) \geq 1 - p$$

$$F^{-1}(p) = q(p)$$

Kwantyle dla rozkładu Laplace'a

$$F(t) = \int_{-\infty}^t \frac{1}{4} e^{-|x|/2} dx$$

Z symetrii:

$$F(0) = \frac{1}{2}$$

$$\begin{aligned} F(t) &= \frac{1}{2} + \operatorname{sgn}(t) \int_0^{|t|} \frac{1}{4} e^{-x/2} dx = \frac{1}{2} + \operatorname{sgn}(t) \left[-\frac{1}{2} e^{-x/2} \Big|_0^{|t|} \right] = \frac{1}{2} + \operatorname{sgn}(t) \left[-\frac{1}{2} e^{-|t|/2} + \frac{1}{2} \right] = \\ &= \begin{cases} \frac{1}{2} e^{t/2} & t < 0 \\ 1 - \frac{1}{2} e^{-t/2} & t \geq 0 \end{cases} \end{aligned}$$

Otrzymana dystrybuanta jest ciągła i jest ściśle rosnąca. Możemy zatem policzyć funkcję odwrotną, czyli

$$F(t) = p$$

Z warunku $F(0) = \frac{1}{2}$ mamy dla $p \leq \frac{1}{2}$

$$\frac{1}{2}e^{t/2} = p \Rightarrow t/2 = \log(2p) \Rightarrow 2\log(2p)$$

Dla $p > 1/2$ mamy analogicznie $-2\log(2(1-p))$.

7. Standaryzacja

Pokazać, korzystając z pojęcia dystrybuanty, że standaryzowana zmienna losowa $Y = (X - \mu)/\sigma$, powstająca ze zmiennej X o rozkładzie $N(\mu, \sigma)$ ma rozkład $N(0, 1)$.

Rozwiązanie:

$$X \sim N(\mu, \sigma^2)$$

$$\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

$$EX = \mu, \quad VarX = \sigma^2$$

X, Y - niezależne zmienne losowe o rozkładzie normalnym

$X + Y$ mają rozkład normalny

$$E(X + Y) = EX + EY$$

$$\mu_{X+Y} = \mu_X + \mu_Y$$

$$Var(X + Y) = VarX + VarY$$

$$\sigma_{X+Y}^2 = \sigma_X^2 + \sigma_Y^2$$

X - zmienna losowa o rozkładzie normalnym, $aX + b$ też ma rozkład normalny

$$Y = aX + b$$

$$\mu_Y = EY = E(aX + b) = aEX + b = a\mu_X + b$$

$$\sigma_Y^2 = VarY = Var(aX + b) = Var(aX) = a^2 VarX = a^2 \sigma_X^2$$

$$X \sim N(\mu, \sigma^2), Y = \frac{X-\mu}{\sigma}$$

$$EY = 0$$

$$VarY = ?$$

Uwaga - wystarczy sprawdzić dla sytuacji gdy $X \sim N(0, 1)$

$$Y = aX + b$$

$$P(Y \leq t) = P\left(X \leq \frac{t-b}{a}\right) = F_X\left(\frac{t-b}{a}\right)$$

$$f_Y(t) = \frac{d}{dt}P(Y \leq t) = f_X\left(\frac{t-b}{a}\right) \frac{1}{a}$$

$$f_X(t) = \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}}$$

$$f_Y(t) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(t-b)^2}{2}} \frac{1}{a} = \frac{1}{\sqrt{2\pi}a} e^{-\frac{(t-b)^2}{2a^2}} \Rightarrow N(b, a^2)$$

9.

10. W urnie są trzy czarne kule i jedna biała. Losujemy kolejno i bez zwracania kule aż do momentu wyciągnięcia białej. Niech X - liczba wyciągniętych kul. Oblicz $E(X)$.

Rozwiązanie:

$$P(X = 1) = \frac{1}{4}$$

$$P(X = 2) = \frac{3}{4} \cdot \frac{1}{3} = \frac{1}{4}$$

$$P(X = 3) = \frac{3}{4} \cdot \frac{2}{3} \cdot \frac{1}{2} = \frac{1}{4}$$

$$P(X = 4) = \frac{1}{4}$$

$$EX = 2,5$$

11. Co jest bardziej prawdopodobne: wygrać z równorzędnym przeciwnikiem dwie partie z trzech, czy cztery partie z sześciu?

Rozwiązanie:

$$P(2 \text{ z } 3) = \binom{3}{2} \left(\frac{1}{2}\right)^3 = \frac{3}{8}$$

$$P(4 \text{ z } 6) = \binom{6}{4} \left(\frac{1}{2}\right)^6 = \frac{15}{64}$$

12.

13.